

华中科技大学

模式识别课程设计报告

基于事件相机的目标跟踪

小组成员 陈烨健、陈昌哲、金天翼、王迪、张荣轩

指导教师 昌毅

学院专业 人工智能 2303 班

完成日期 2026 年 7 月 6 日

[†] 以首字母顺序排名，贡献不分先后

摘要

目标跟踪是视觉感知系统中的核心任务之一，在无人驾驶、机器人、无人机和智能监控等复杂动态场景中具有重要应用价值。传统帧式相机依赖固定帧率采样与积分曝光成像机制，在高速运动、遮挡干扰、运动模糊以及光照剧烈变化条件下容易出现跟踪漂移和目标丢失。事件相机采用像素级异步触发机制，仅在亮度变化超过阈值时输出事件流，具备微秒级时间分辨率、高动态范围和低信息冗余等特点，为极端场景下的连续时空建模提供了新的数据表达形式。

本文围绕基于事件相机的目标跟踪任务展开系统研究。首先，梳理事件相机成像机理与数据表示方法，抽象出事件目标跟踪的严格数学形式化定义，并对纯事件跟踪与 RGB-E 融合跟踪的核心算法路线及前沿方向进行了系统分类与归纳。其次，深入分析了事件与图像融合框架中的时空对齐、模态质量评估和特征交互机制。随后，对 ViPT 和 SDSTrack 两种代表性跟踪算法进行复现，在 VisEvent 公开数据集上完成训练、测试与结果记录，并对原始方法与改进方法进行了系统对比。

在统一的硬件环境与评测协议下，原始 ViPT 在 VisEvent 上的 AUC 为 62.0，Precision@20 为 75.4；本文复现模型的 AUC 为 61.2，Precision@20 为 74.5。在此基础上，本文提出的轻量级在线模板更新改进版本，将 AUC 和 Precision@20 在复现基线上分别提升了 0.7 和 0.9。对于 SDSTrack，原始论文报告在 VisEvent 上的 AUC 为 59.7，Precision@20 为 76.7；本文复现模型的 AUC 为 58.3，Precision@20 为 75.1，复现偏差均控制在合理范围内。相关代码、预训练权重及评测脚本已在 GitHub 开源：<https://github.com/kriss-spy/EvTrack>。

最后，本文结合复现与改进过程中的失败案例，深入探讨了当前 RGB-E 融合跟踪模型在时序信息利用、严重遮挡处理等方面存在的固有缺陷，并提出了针对性的后续优化方案与展望。

关键词：事件相机；目标跟踪；RGB-E 融合；ViPT；SDSTrack；VisEvent；在线模板更新

Abstract

Target tracking is fundamental in visual perception, holding significant value in complex dynamic scenarios like autonomous driving and robotics. Traditional frame-based cameras, relying on fixed frame-rate sampling, are prone to tracking drift under high-speed motion, occlusion, and drastic illumination changes. Event cameras adopt asynchronous pixel-level triggering, outputting streams only when brightness changes exceed a threshold. Their microsecond temporal resolution and high dynamic range provide novel data representations for extreme scenarios.

This paper conducts systematic research on event-based target tracking. First, we review event camera mechanisms, abstract strict mathematical formulations for tracking tasks, and categorize core algorithms and frontiers of Event-Only and RGB-E fusion tracking. Second, we analyze spatiotemporal alignment and feature interaction mechanisms in fusion frameworks. Subsequently, we reproduce ViPT and SDSTrack on the VisEvent dataset, conducting systematic comparisons between original and improved methods.

Under a unified evaluation protocol, the original ViPT achieved 62.0 AUC and 75.4 Precision@20 on VisEvent; our reproduction achieved 61.2 and 74.5, respectively. Building upon this, our lightweight online template update strategy improved the AUC and Precision@20 by 0.7 and 0.9 over the baseline. For SDSTrack, the original paper reported 59.7 AUC and 76.7 Precision@20; our reproduction achieved 58.3 and 75.1, with deviations within a reasonable range. Related code and weights are open-sourced on GitHub: <https://github.com/kriss-spy/EvTrack>.

Finally, analyzing failure cases, we discuss inherent shortcomings of current RGB-E models in temporal utilization and occlusion handling, proposing targeted future optimizations.

Keywords: event camera; object tracking; RGB-E fusion; ViPT; SDSTrack; VisEvent; on-line template update

目录

摘要	I
Abstract	II
第一章 引言	1
第二章 事件相机基础	3
2.1 事件相机原理	3
2.1.1 与传统帧式相机的本质区别	3
2.1.2 事件生成模型	4
2.1.3 事件与亮度的时空导数关系	5
2.2 代表性事件相机传感器	5
2.3 事件数据表示方法	5
第三章 事件相机目标跟踪	8
3.1 问题定义	8
3.1.1 Event-Only 单目标跟踪	8
3.1.2 Event-Only 多目标跟踪	9
3.1.3 RGB-E 单目标跟踪	9
3.1.4 RGB-E 多目标跟踪	10
3.2 核心算法路线	10
3.2.1 Event-Only 跟踪方法	10
3.2.2 RGB-Event 融合跟踪方法	12
3.2.3 前沿研究方向	15
3.3 技术路线小结	17
第四章 ViPT 与 SDSTrack 算法复现	18
4.1 ViPT 算法分析与复现	18
4.1.1 方法概述	18
4.1.2 实验环境与训练设置	18
4.1.3 复现结果与分析	19
4.2 SDSTrack 算法分析与复现	21
4.2.1 方法概述	21
4.2.2 复现策略与实验环境	22
4.2.3 复现结果与分析	23

第五章 基于 ViPT 的改进方法设计与实验	24
5.1 ViPT 原始方法存在的问题	24
5.2 改进思路	24
5.3 动态模块原理	25
5.4 改进信息流设计	25
5.5 改进结果与分析	26
5.5.1 定量结果分析	26
5.5.2 定性结果分析	27
5.5.3 实时性分析	28
5.6 后续改进方案猜想	29
第六章 总结与展望	31
6.1 工作总结	31
6.2 不足之处	31
6.3 未来展望	31
附录 A 改进算法流程	37

第一章 引言

目标跟踪旨在给定初始帧中的目标状态后，在后续视频序列中持续估计目标的位置、尺度和外观变化，是视觉感知系统中的基础问题之一。由于跟踪结果可以为目标定位、行为理解、运动预测和闭环控制提供连续状态信息，该任务已广泛应用于智能监控、人机交互、机器人感知、无人系统和自动驾驶等场景 [2]。在这些应用中，目标往往处于非受控环境，跟踪器不仅需要保持较高的定位精度，还需要在背景杂乱、遮挡、快速运动和光照变化等条件下维持稳定性。

传统基于帧相机的目标跟踪方法通常依赖固定帧率采样和积分曝光成像机制。该成像方式能够提供丰富的纹理、颜色和语义信息，但在复杂动态场景中存在天然局限：一方面，高速运动或相机抖动会在曝光时间内造成运动模糊，从而破坏目标边缘和局部纹理，已有研究表明严重运动模糊会显著降低视觉跟踪性能 [2, 6]；另一方面，遮挡、相似目标干扰和外观突变仍是视觉跟踪中的长期挑战，尤其在真实场景中会导致模板漂移和目标丢失 [2]。此外，固定帧率采样会引入时间冗余和帧间延迟，在高速目标或实时控制任务中难以充分刻画连续运动过程。

事件相机为上述问题提供了新的感知方式。不同于传统相机按固定频率输出完整图像，事件相机在像素亮度变化超过阈值时异步触发事件，输出形式通常为包含像素位置、时间戳和极性的事件流。事件视觉综述指出，事件相机具有微秒级时间分辨率、高动态范围、低功耗和低数据冗余等特点，适合描述高速运动和极端光照下的动态变化 [4]。在目标跟踪任务中，这些特性使事件数据能够补充帧图像在运动模糊、低照度和强光场景下的不足。VisEvent 工作也表明，可见光图像与事件流在纹理细节、慢速运动、高速运动和低照度感知方面具有互补性，因此二者协同有助于提升跟踪可靠性 [28]。

然而，仅依赖事件流进行目标跟踪也存在限制。事件相机只对亮度变化响应，缺少颜色、绝对亮度和静态纹理信息；当目标静止、局部运动不明显或背景噪声较强时，事件数据可能出现触发不足或结构稀疏的问题 [4]。因此，RGB-E 融合跟踪成为事件相机目标跟踪中的重要方向：RGB 图像提供稳定的外观、颜色和语义线索，事件流提供高时间分辨率的运动和边缘变化信息。VisEvent 通过构建大规模可见光-事件协同跟踪 benchmark 并引入跨模态 Transformer，推动了 RGB-E 跟踪从单模态扩展向跨模态融合发展 [28]。

尽管 RGB-E 融合跟踪已经取得进展，现有方法仍面临若干问题。首先，事件流的高时间分辨率优势并不等同于被模型充分利用，许多方法仍将事件流压缩为事件图像或帧级表示，导致细粒度时序信息被削弱。其次，多模态跟踪模型需要处理 RGB 与事件模态之间的时间同步、空间对齐、质量波动和特征交互问题 [28]。ViPT 通过视觉提示机制将冻结的 RGB 预训练主干迁移到 RGB+Event 等多模态任务，在参数效率方面具有优势，但其事件时序建模和模板更新机制仍较为有限 [43]。SDSTrack 则通

过对称适配器和自蒸馏缓解多模态差异与 RGB 主导问题，但如何在复杂动态场景中进一步利用事件流的时序结构仍值得研究 [8]。

围绕上述问题，本文面向复杂动态场景下的基于事件相机目标跟踪任务，开展相关工作调研、代表算法复现和轻量改进探索。本文主要贡献如下：

- 抽象出事件相机目标跟踪的严格数学形式化定义，涵盖 Event-Only 与 RGB-E 的单目标及多目标跟踪设定，并据此对现有核心算法路线进行了系统分类与梳理。
- 复现 ViPT 和 SDSTrack 两种代表性 RGB-E 跟踪算法，并在 VisEvent 数据集上完成训练、测试与指标分析。
- 基于 ViPT 设计轻量在线模板更新策略，在不改变主体框架的前提下探索动态模板对跟踪性能的影响。
- 从精度、成功率、属性场景、实时性和失败案例等角度系统分析复现方法和改进方法的性能与局限。

本文其余部分组织如下：第 2 章介绍事件相机的基本原理、代表性传感器及事件数据的主流表示方法；第 3 章给出事件相机目标跟踪的问题定义，梳理核心算法路线并概述前沿研究方向；第 4 章详细分析 ViPT 和 SDSTrack 两种代表算法的设计动机、复现设置及实验结果；第 5 章介绍基于 ViPT 的轻量在线模板更新改进方法，并给出详细的实验结果与系统分析；第 6 章对全文工作进行总结，探讨现有方法的不足并对未来研究方向进行展望。

第二章 事件相机基础

要深入理解事件相机跟踪方法，首先需要掌握事件相机这一新型传感器的内在工作机制。为此，本章将系统介绍事件相机的基本原理，包括其事件生成模型、与传统相机的本质区别，以及现有事件数据的主流表示方法，为后续讨论事件相机目标跟踪提供必要的理论基础。

2.1 事件相机原理

2.1.1 与传统帧式相机的本质区别

传统可见光相机采用全局曝光、同步读出的机制：所有像素在固定时间间隔内同时感光，记录绝对亮度，形成一帧图像后以恒定帧率输出。这种“帧”的概念与场景动态无关，导致运动模糊、低帧率延迟、动态范围受限等固有缺陷。

事件相机则完全摒弃了“帧”的概念。其灵感来源于生物视网膜中的“瞬变通路”，每个像素独立、异步地监测自身接收到的对数光强变化。当变化量超过预设阈值时，该像素立即输出一个“事件”（event），并复位监测状态。因此，事件相机的输出不是图像序列，而是一个异步、稀疏的事件流，数据率与场景动态成正比。




图 2.1 帧式相机与事件相机成像机制对比。帧式相机以固定频率同步输出完整图像，而事件相机由像素独立监测亮度变化，仅在变化超过阈值时异步输出稀疏事件。

2.1.2 事件生成模型

令 $I(\mathbf{x}, t)$ 为像素 $\mathbf{x} = (x, y)^T$ 在时刻 t 接收到的光强。事件相机像素通常采用对数光强 $L(\mathbf{x}, t) = \log I(\mathbf{x}, t)$ 以压缩动态范围。设某像素上一次触发事件的时间为 t_{last} ，当前时刻为 t ，则该像素在此期间的对数光强变化量为：

$$\Delta L(\mathbf{x}, t) = L(\mathbf{x}, t) - L(\mathbf{x}, t_{last})$$

当 $|\Delta L|$ 超过预设的对比灵敏度阈值 C 时，像素立即产生一个事件。事件定义为四元组：

$$e_k = (x_k, y_k, t_k, p_k)$$

其中 (x_k, y_k) 为像素坐标， t_k 为事件发生时间（微秒级精度）， p_k 为极性，表示亮度增加（ON 事件）或减少（OFF 事件）。事件生成条件可写为：

$$\Delta L(\mathbf{x}_t, t_k) = p_k C, \quad p_k \in \{-1, +1\}$$

该模型表明，每个事件编码的是相对亮度变化达到固定幅度的时刻，而非绝对亮度值。




图 2.2 对数光强变化与事件触发阈值示意图。当像素对数光强相对于上一次触发时刻的变化量达到正阈值 $+C$ 或负阈值 $-C$ 时，分别产生 ON 或 OFF 事件，并将当前对数光强作为新的参考值。

2.1.3 事件与亮度的时空导数关系

若两次事件的时间间隔 $\Delta t_k = t_k - t_{\text{last}}$ 很小，将 L 进行一阶泰勒展开后可得：

$$\Delta L(\mathbf{x}_k, t_k) \approx \frac{\partial L}{\partial t}(\mathbf{x}_k, t_k) \Delta t_k.$$

将事件生成条件代入，可得：

$$\frac{\partial L}{\partial t}(\mathbf{x}_k, t_k) \approx \frac{p_k C}{\Delta t_k}.$$

因此，事件间的时间间隔间接反映了亮度的时间导数：亮度变化越快（ $\frac{\partial L}{\partial t}$ 越大），同一像素相邻事件的时间间隔 Δt 越短。这一关系是许多事件驱动算法（如光流、图像重建）的物理基础。

进一步假设场景光照恒定，则亮度变化仅由运动引起。利用亮度恒常性假设，对式进行线性化可得：

$$\Delta L \approx -\nabla L \cdot \mathbf{v} \Delta t,$$

其中 ∇L 为亮度梯度， $\mathbf{v}$ 为边缘在图像平面上的运动速度（光流）。该式表明：事件主要由运动边缘触发，且事件的极性取决于亮度梯度方向与运动方向的相对关系。

2.2 代表性事件相机传感器

根据是否同时输出静态强度（灰度），常见事件相机分为三类：

- DVS (Dynamic Vision Sensor): 仅输出事件，纯动态信息，像素最小、功耗最低。
- ATIS (Asynchronous Time-based Image Sensor): 每个像素包含一个 DVS 子单元和一个强度测量子单元，事件触发后读取绝对强度，动态范围大于 120 dB，但像素面积较大，暗光下延迟较高。
- DAVIS (Dynamic and Active Pixel Vision Sensor): 将 DVS 与标准 APS（灰度）像素共享同一光电二极管，可同时输出事件和同步帧，是目前最广泛使用的 RGB-Event 融合传感器。

2.3 事件数据表示方法

事件相机输出的原始数据是一个异步、稀疏的四元组序列： $\{(x_i, y_i, t_i, p_i)\}_{i=1}^N$ 。与稠密的 RGB 图像网格相比，事件数据具有以下特点：

- 异步性：事件的时间戳不落在任何固定栅格上；
- 稀疏性：只有亮度变化的像素才产生事件，平坦区域无输出；
- 极性信息：仅提供变化方向（+1/-1），不提供变化幅度；

- 高时间分辨率：相邻事件间隔可达微秒级。

事件数据可被转换为多种表示形式，以适应不同的视觉任务和算法需求。根据是否保留时间信息以及聚合程度，这些表示涵盖了从原始事件流到密集张量的不同层次，各有侧重。以下介绍几种主要的表示方法。

(1) 单个事件 (Individual Event)： 直接将每个事件作为最小处理单元，通常配合事件驱动滤波或脉冲神经网络 (SNN) 使用。例如，概率滤波器（卡尔曼滤波、粒子滤波）每到达一个事件即更新状态；SNN 中每个事件作为输入尖峰，触发神经元的积分与发放。该表示延迟最低，但每个事件携带的信息量极少，必须依靠系统状态（由历史事件积累）才能产生有意义的输出。

(2) 事件包 (Event Packet) 将一段时间或固定数量的事件集合为一个包： $\mathcal{P} = \{e_i\}_{i=1}^{N_e}$ ，保留所有事件的完整信息（坐标、时间戳、极性）。包内假设运动或场景结构在该时空窗口内近似恒定。典型应用包括立体匹配、运动补偿以及光流估计。

(3) 事件帧 (Event Frame) 在固定时间窗口 ΔT 内，对每个像素累积事件的极性（或计数），生成二维图像。例如：

$$E(x, y) = \sum_{t_i \in \Delta T} p_i$$

该表示简单直观，可直接输入 CNN。但缺点是完全丢弃了时间戳信息，且对窗口大小敏感。适用于需要快速适配现有图像算法的场景，如位姿估计、光流。

(4) 时间表面 (Time Surface) 时间表面为每个像素存储一个标量，表示该像素“最近一次事件发生的时间”。常用指数衰减核：

$$TS(x, y, t) = \exp\left(-\frac{t - t_{\text{last}}(x, y)}{\tau}\right)$$

其中 t_{last} 为最近事件时间戳， τ 为时间常数。TS 将事件流转换为一张“活动图”，其像素值越高表示运动越新。TS 对边缘方向敏感，常用于角点检测、光流、物体识别。缺点是在高纹理区域，每个像素频繁触发事件，导致 TS 被快速覆盖，信息丢失。

(5) 体素网格 (Voxel Grid) 将时空体积 $[0, W) \times [0, H) \times [t, t + \Delta t)$ 划分为 $B_x \times B_y \times B_t$ 个网格（体素）。每个事件根据其坐标和时间戳，通过双线性或三线性插值将极性投影到邻近体素。例如，可生成一个 B_t 通道的伪图像，每个通道对应一个时间切片。体素网格保留了时间维度的分布信息，比事件帧更精确，但计算量和内存占用更高。常用于光流、深度估计、端到端学习。

(6) 3D 点集 (3D Point Set) 将事件包内的每个事件视为三维空间中的一个点，即 $(x_k, y_k, t_k) \in \mathbb{R}^3$ ，时间维度被显式保留为几何坐标。该表示是稀疏的，可直接应用于基于点云的几何处理方法，如平面拟合、RANSAC 或 PointNet。典型应用包括光流估计（局部平面拟合）和运动分割。

(7) 图像平面上的点集 (Point Sets on Image Plane) 将事件视为图像平面上不断演化的 2D 点集（忽略时间戳，仅使用 x, y 坐标）。该表示常用于早期基于迭代最近点 (ICP) 或均值漂移 (Mean-shift) 的形状跟踪方法，其中事件点作为目标边缘的采样，通过迭代对齐实现低延迟跟踪。其优势是无需生成密集图像，但依赖初始模板且对遮挡敏感。

(8) 运动补偿图像 (Motion-Compensated Event Image) 该表示不直接由事件生成，而是依赖于一个运动假设（如相机旋转速度、光流场）。将事件根据运动模型“扭曲” (warp) 到同一参考时刻，再累计极性。若运动假设正确，扭曲后的事件会重叠形成锐利边缘图像（称为 IWE, Image of Warped Events）。运动补偿图像本身可作为运动估计的目标函数：对齐质量越高，图像越锐利。该方法充分利用了事件的连续时间特性，应用于运动估计、深度恢复、运动分割。

(9) 重建图像 (Reconstructed Image) 通过积分事件并加入正则化（如平滑先验、学习先验），可恢复场景的绝对亮度图像。重建图像是理想的不变于运动的表示，可直接用于传统特征检测（如 Harris 角点）。但重建计算量大，且依赖于运动或平滑假设。

最终所有事件数据表示方法的对比如下表所示：

表 2.1 事件数据表示方法对比

表示方法	保留时间信息	空间分辨率	计算开销	典型延迟	适用任务
单个事件	完整（逐事件）	像素级	极低	最低	SNN、滤波器
事件包	完整（包内）	像素级	低	取决于包大小	立体、运动补偿
事件帧	无	像素级	低	取决于窗口	快速适配图像方法
时间表面	部分（最近时间）	像素级	低	低	角点、光流、识别
体素网格	较好（多时间切片）	可调	中高	取决于切片数	深度学习、光流
3D 点集	完整（作为坐标）	像素级	中	取决于包大小	几何拟合、PointNet
图像平面点集	无（仅空间）	像素级	低	低	ICP 跟踪、形状匹配
运动补偿图像	完整（通过 warp）	亚像素级	中	取决于优化	运动估计、分割
重建图像	间接	像素级	高	高	传统特征提取

第三章 事件相机目标跟踪

从输入模态看，事件相机目标跟踪可以分为两条主要技术路线：一类仅使用事件流进行跟踪，强调低延迟、高时间分辨率和高速运动鲁棒性；另一类将事件流与 RGB 图像融合，利用两种模态在外观纹理和动态变化上的互补性。从跟踪对象数量看，又可分为单目标跟踪与多目标跟踪。本章进行问题定义，梳理典型方法、数据集与评价协议，为后续 ViPT 和 SDSTrack 的复现分析提供背景，最后概述一下最近的研究方向。

3.1 问题定义

3.1.1 Event-Only 单目标跟踪

Event-Only 单目标跟踪仅以事件表示序列 $\{X_k^E\}_{k=1}^T$ 为输入。这里的索引 k 不对应传统意义上的视频帧编号，而对应连续事件流进行离散化后得到的第 k 个事件时间步，其中 T 表示总事件时间步数。具体而言， X_k^E 可由事件流在时间窗口 W_k 内的观测构造得到，即

$$X_k^E = \Phi(\mathcal{E}|_{W_k}),$$

其中 $\mathcal{E}|_{W_k}$ 表示落入时间窗口 W_k 内的事件子集， W_k 可由固定时间长度、固定事件数或体素化规则定义， $\Phi(\cdot)$ 表示事件编码过程。换言之，Event-Only 跟踪中的序列本质上是对异步事件流进行结构化离散后的时序表示，而非天然存在的帧序列 [4, 31]。

在给定初始时刻目标状态 b_1 的条件下，跟踪器需要在后续时刻持续估计同一目标的空间状态。记第 k 个时刻的真实目标状态为轴对齐边界框

$$b_k = (x_k, y_k, w_k, h_k),$$

其中 (x_k, y_k) 表示目标中心位置， w_k 与 h_k 分别表示目标宽度与高度。记 $\hat{b}_k$ 为第 k 个时刻的预测目标状态， θ 为模型参数，则该任务可形式化表示为

$$\hat{b}_k = f_\theta(X_1^E, X_2^E, \dots, X_k^E, b_1), \quad k = 2, \dots, T.$$

若写成递推形式，则可进一步写为

$$\hat{b}_k = f_\theta(\hat{b}_{k-1}, X_k^E, s_{k-1}), \quad s_k = \Psi_\theta(s_{k-1}, X_k^E, \hat{b}_k),$$

其中 s_k 表示跟踪器在第 k 个时刻的内部状态或历史表征。该定义强调，Event-Only 单目标跟踪并不是简单地从 RGB-E 跟踪中去掉 RGB 模态，而是要求模型仅凭事件观测完成目标定位与状态传播，因此其性能更直接依赖于事件表示质量、时间建模能力以及对噪声事件的抑制能力 [4, 31]。从任务目标看，Event-Only 路线追求的是

在仅有事件信号可用的前提下, 实现低延迟、高动态范围条件下的连续目标状态估计; 其局限在于事件数据缺少颜色、绝对亮度和静态纹理信息, 当目标静止、局部运动较弱或背景噪声较强时, 事件触发不足或结构稀疏会显著增加跟踪难度 [4, 28, 31]。

3.1.2 Event-Only 多目标跟踪

Event-Only 多目标跟踪同样仅依赖事件观测, 但输出由单目标状态扩展为多目标状态集合。为与单目标设定保持一致, 仍记 T 为总事件时间步数, X_k^E 为第 k 个事件时间步对应的事件表示。记第 k 个时刻的真实多目标状态为

$$\mathcal{B}_k = \{(b_k^j, \text{id}^j)\}_{j=1}^{M_k},$$

其中 M_k 为该时刻目标数量, b_k^j 为第 j 个目标的空间状态, id^j 为目标身份标识; 相应地, $\hat{\mathcal{B}}_k$ 表示预测的多目标状态集合。则该任务可写为

$$\hat{\mathcal{B}}_k = g_\theta(X_1^E, X_2^E, \dots, X_k^E), \quad k = 1, \dots, T.$$

与单目标情形不同, 该任务的输出并非若干彼此独立的边界框, 而是满足身份一致性约束的状态集合。模型既要判断当前存在的目标, 还要维持其与历史轨迹的对应关系。受事件流异步、稀疏以及背景运动干扰的影响, 目标交汇、遮挡和并行运动会显著增加数据关联难度, 因此该任务更依赖稳健的关联机制与时序一致性建模。

3.1.3 RGB-E 单目标跟踪

RGB-E 单目标跟踪以联合观测序列 $\{X_k\}_{k=1}^T$ 为输入, 其中第 k 个时刻的 RGB 帧记为 I_k , 与之对应的事件表示记为 X_k^E , 联合观测定义为

$$X_k = (I_k, X_k^E).$$

这里的 T 表示同步观测步总数。给定首帧目标初始状态 b_1 , 跟踪器需在后续时刻输出目标预测状态。仍记 $b_k = (x_k, y_k, w_k, h_k)$ 为第 k 个时刻的真实目标状态, $\hat{b}_k$ 为对应预测状态, 则该任务可形式化表示为

$$\hat{b}_k = h_\theta(X_1, X_2, \dots, X_k, b_1), \quad k = 2, \dots, T.$$

对应的递推形式可写为

$$\hat{b}_k = h_\theta(\hat{b}_{k-1}, X_k, s_{k-1}), \quad s_k = \Gamma_\theta(s_{k-1}, X_k, \hat{b}_k).$$

该设定的核心在于: 一方面利用 RGB 模态提供较稳定的外观、纹理与语义信息, 另一方面利用事件模态提供高时间分辨率和高动态范围下的运动变化信息, 从而在高速运动、低照度、光照剧变和运动模糊等复杂动态场景中提升跟踪鲁棒性 [8, 28, 43]。VisEvent 等工作表明, RGB 与事件流在慢运动与高速运动、纹理细节与运动边缘、正

常光照与极端曝光条件下具有明显互补性，因此 RGB-E 跟踪的目标并不是简单叠加两种模态，而是在不同场景属性下自适应利用更有效的信息来源 [28]。进一步看，RGB-E 单目标跟踪的难点也不只是双模态输入本身，而在于如何稳定处理两类模态之间的差异，包括跨模态时间同步、空间对齐、特征交互和质量波动，以及模态差异过大、RGB 主导导致事件信息利用不足等问题 [8, 28, 43]。

3.1.4 RGB-E 多目标跟踪

RGB-E 多目标跟踪同时接收 RGB 帧与事件表示，输出带身份标识的多目标状态集合。仍记第 k 个时刻的联合观测为 $X_k = (I_k, X_k^E)$ ， T 为同步观测步总数。记第 k 个时刻的真实多目标状态为

$$\mathcal{B}_k = \{(b_k^j, \text{id}^j)\}_{j=1}^{M_k},$$

其中 M_k 为目标数量， b_k^j 为第 j 个目标的空间状态， id^j 为目标身份标识；相应地， $\hat{\mathcal{B}}_k$ 表示预测的多目标状态集合。则该任务可写为

$$\hat{\mathcal{B}}_k = q_\theta(X_1, X_2, \dots, X_k), \quad k = 1, \dots, T.$$

相较于 RGB-E 单目标跟踪，该任务同时叠加了两类复杂性：其一来自多模态融合本身，包括时间同步、空间对齐与模态平衡；其二来自多目标跟踪，包括检测、关联、重识别与身份一致性维护。换言之，RGB-E 多目标跟踪既要回答如何融合两类观测，又要回答如何在连续时序中区分并保持多个目标身份，因此问题规模和系统复杂度都更高。

3.2 核心算法路线

3.2.1 Event-Only 跟踪方法

Event-Only 跟踪方法仅以事件相机输出的事件流作为输入。给定初始时刻的目标状态，跟踪器需要在后续事件序列中持续估计目标边界框或目标中心位置。由于事件流本身是异步、稀疏且带有极性的四元组序列，Event-Only 跟踪的关键不只是目标匹配，还包括如何把连续事件组织成适合建模的时空表示。

早期方法通常采用几何或滤波框架，将一段时间窗口内的事件点视为目标边缘采样，通过聚类、均值漂移、粒子滤波或运动补偿实现目标状态估计。这类方法延迟低、解释性强，但依赖手工特征和运动假设，在背景事件噪声较强、目标形变明显或遮挡发生时容易出现漂移。随着深度学习方法发展，研究者逐渐将事件帧、时间表面、体素网格或运动补偿事件图输入到 CNN、Transformer 或状态空间模型中，使模型能够学习更稳定的时空特征。

近年来的 Event-Only 跟踪更加重视事件流的连续时间属性。HDETrack 利用多模态教师网络向事件学生网络蒸馏知识，使测试阶段仅依赖事件信号即可完成高分辨率跟踪 [31]；HDETrack V2 进一步扩展了事件流建模框架，并引入高分辨率事件跟踪基




图 3.1 Event-Only 目标跟踪基本流程。跟踪器仅以事件流为输入，首先将异步事件转换为事件帧、时间表面或体素网格等表示，再通过时空特征建模和跟踪头输出目标状态。

准 [26]；MambaEVT 则将状态空间模型引入事件流目标跟踪，利用线性复杂度序列建模处理长时间事件依赖 [30]。这些方法表明，Event-Only 跟踪已经从早期的事件点几何匹配，逐步转向以大规模数据、知识蒸馏和长序列时序建模为核心的深度跟踪范式。

Event-Only 跟踪的优势在于传感器输入单一、延迟低、动态范围高，适合高速运动、强光变化和低功耗场景；其局限也十分明显：事件数据缺少颜色和绝对亮度信息，目标静止或局部运动较弱时触发不足，且事件噪声会降低边界结构的稳定性。因此，Event-Only 方法通常更依赖时序建模能力、事件表示质量和鲁棒的在线更新策略。

Event-Only 跟踪常用数据集和评价协议与 RGB-Event 路线并不完全相同。EventVOT 是当前具有代表性的单模态事件跟踪基准，分辨率达到 1280×720 ，共包含 1141 个事件视频，并明确区分训练、验证和测试子集 [31]。此外，FE108、FE240Hz、EED 等数据也常被用于低分辨率或高速场景下的事件跟踪评测。表 3.1 汇总了几类常见 Event-Only 数据集。

表 3.1 Event-Only 目标跟踪常用数据集

数据集	模态	特点	主要用途
EED	Event	早期事件相机跟踪数据，规模较小，常用于基础算法验证	传统事件跟踪与滤波方法评估
FE108	Event / Frame-Event	短期事件跟踪数据，分辨率较低，包含多类运动场景	低分辨率事件跟踪与 RGB-E 对比
FE240Hz	Event / Frame-Event	高帧率帧-事件数据，适合高速运动场景	高速目标跟踪与事件表示评估
EventVOT	Event	1141 个高分辨率事件视频，分辨率 1280×720	高分辨率 Event-Only 跟踪基准

在评价协议上，Event-Only 单目标跟踪通常沿用 OPE（one-pass evaluation）设置：跟踪器仅在第一帧或初始事件窗口获得目标标注，随后在整段序列上逐步预测目标状态。常用指标包括成功率 SR、精度 PR、归一化精度 NPR、边界框重叠曲线 AUC 以

及实时性 FPS。EventVOT 官方评测工具同时提供 SR、PR、NPR、BOC 以及属性级分析，用于衡量不同方法在高速运动、遮挡、尺度变化和复杂背景等条件下的稳定性。表 3.2 给出了常用指标含义。

表 3.2 Event-Only 跟踪常用评价指标

指标	含义
SR / Success	预测框与真实框 IoU 超过不同阈值时的成功率，通常取成功曲线 AUC 作为综合指标
PR / Precision	预测中心点与真实中心点距离小于给定像素阈值时的比例，常用 20 像素阈值或完整精度曲线
NPR / Normalized Precision	将中心误差按目标尺度归一化后的精度，降低不同目标尺寸对结果的影响
BOC	对边界框中心、尺度和重叠质量进行综合评价，用于补充 SR/PR 对框质量的刻画
FPS	每秒处理帧数或事件窗口数，用于衡量跟踪器实时性

表 3.3 给出了 EventVOT 官方 benchmark 中部分代表模型的公开结果。可以看到，HDETrack 在仅使用事件输入的前提下，在 SR、PR 和 NPR 三项指标上均优于直接迁移的主流 RGB 跟踪器，说明针对事件流设计的表示学习和蒸馏策略对于 Event-Only 跟踪至关重要。

表 3.3 EventVOT 测试集代表模型指标对比（数据引自官方 benchmark）

方法	SR ↑	PR ↑	NPR ↑
HDETrack	0.578	0.622	0.735
AiATrack	0.574	0.597	0.728
OTrack	0.554	0.604	0.711
PrDiMP50	0.555	0.572	0.704
SimTrack	0.554	0.575	0.699
TransT	0.543	0.565	0.688
DiMP50	0.526	0.511	0.672

综合来看，Event-Only 路线适用于高速运动、强光变化、低功耗和 RGB 图像不可用的场景，能够充分发挥事件相机低延迟和高动态范围的优势；但其对静止目标、弱纹理区域和事件噪声较为敏感，缺少颜色与绝对亮度信息也会限制其在复杂语义场景下的辨别能力。

3.2.2 RGB-Event 融合跟踪方法

RGB-Event 融合跟踪的核心目标是将 RGB 图像提供的丰富外观纹理与事件相机的高时间分辨率、高动态范围优势相结合，从而在高速运动、低光照、光照剧变等极端场景下实现稳定、鲁棒的目标跟踪。自该研究方向兴起以来，其技术演进主要体现在融合策略的不断精细化、网络架构的统一化，以及大规模标注数据集的逐步建立。

在研究的初期阶段，学者们主要借鉴多模态融合的一般范式，将事件数据转换为事件帧或时间表面后，与 RGB 图像在不同阶段进行组合。VisEvent 工作 [28] 系统地给出了 RGB-Event 跟踪的三大融合方向：一是在输入层对 RGB 帧与事件图进行简单的加法或通道拼接，直接送入现有 RGB 跟踪器（早期融合）；二是对两模态提取的深

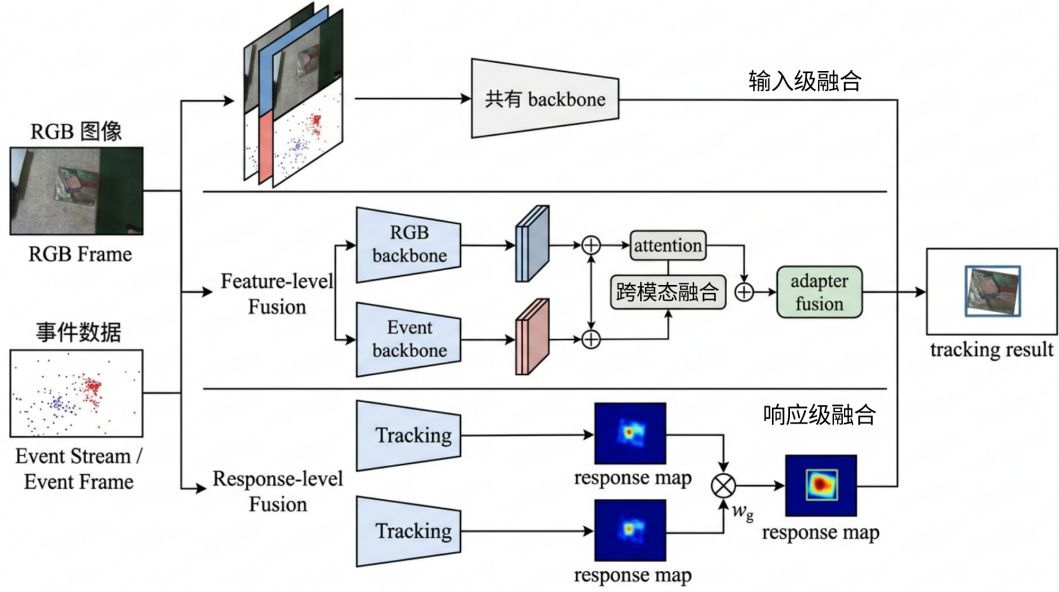


图 3.2 RGB-Event 融合跟踪的典型策略。根据融合发生的位置，可分为输入级融合、特征级融合和响应级融合；其中事件模态提供高时间分辨率的运动线索，RGB 模态提供稳定的外观与语义信息。

度特征进行拼接、逐元素相加、 1×1 卷积、通道注意力或跨注意力等操作（中期特征级融合）；三是在最终的响应图或分类分数层面进行加权组合（晚期响应级融合）。这一分类为后续研究提供了基本框架。与此同时，Liu 等人 [17] 首次尝试从 RGB 帧和事件流中同时提取候选区域，实现了更准确的跟踪定位；Huang 等人 [10] 开发了基于支持向量机的跟踪器，利用事件流的时空分布挖掘候选搜索位置；Gehrig 等人 [5] 提出了异步光度特征跟踪方法（EKLt），通过最小化事件与帧间的光度误差实现亚像素精度的特征跟踪。这些早期工作初步验证了双模态互补的有效性，但融合方式相对简单，未能充分挖掘事件的高时间分辨率特性，且大多采用多阶段处理的流水线结构，难以实现端到端的优化。

随着 Transformer 在计算机视觉领域的成功，研究者开始将其引入 RGB-Event 融合跟踪，以更强的注意力机制实现模态间的精细交互，并逐步从“多模块堆叠”向“单一统一网络”过渡。CEUTrack[22] 将 RGB 图像与事件点体素化后统一转换为 token 序列，在同一个 Transformer 编码器中同时完成特征提取、模态交互与融合，不再需要独立的特征提取网络和单独的融合模块，代表了从多阶段处理向端到端统一建模的重要转变，在 COESOT、VisEvent 等多个数据集上取得了领先性能并达到实时速度。几乎同期，VisEvent[28] 本身提出了跨模态 Transformer 模块，以 RGB 特征作为查询、事件特征作为键与值，实现事件信息对 RGB 特征的增强；AFNet[39] 设计了帧-事件对齐与融合网络，通过跨域特征整合器和自适应加权方案解决了双模态特征的空间与时间不对齐问题；FELT 中的 AMTTrack[29] 进一步引入 Hopfield 检索层，在单流结构中聚合多尺度的 RGB 与事件 token，提升了多尺度表征能力。此外，Zhang 等人 [41] 将多目标跟踪中的时空关联概念引入 RGB-Event 单目标跟踪，设计了空间-时间

Transformer，同时建模目标的外观信息与运动信息，通过候选匹配机制实现对“目标与干扰物”的鲁棒区分，在密集相似物干扰场景下表现突出。




图 3.3 RGB-Event 融合跟踪近期研究热点

近年来，RGB-Event 融合跟踪的研究更加多元化，涌现出频域处理、视觉提示学习、状态空间模型以及事件特性专门建模等多个新方向，融合策略从单纯的网络结构设计扩展到了信号处理、先验学习与长序列建模等领域。在频域处理方面，Wang 等人[25]提出利用快速傅里叶变换将 RGB 与事件数据变换到频域，分离幅度与相位分量，选择性地将事件的高频信息注入 RGB，同时辅以运动引导的稀疏化模块，既突出了运动边缘又降低了骨干网络的计算负担。受大模型中提示学习思想的启发，ViPT[43]等工作利用预训练的 RGB 模型进行微调，通过学习与事件相关的视觉提示来适配事件模态。HPL[23]引入了“中间模态”作为先验支撑，通过帧-事件混合提示器与伪提示学习策略，有效缓解了 RGB 与事件之间的表征差异，并控制了 RGB 主导问题；EventTPT[35]则利用历史轨迹事件图作为“视觉提示”，设计自适应跨模态融合模块解决光照不一致场景下的跟踪漂移问题。在长序列建模方面，Mamba 作为一种具有线性复杂度的状态空间模型，擅长高效处理长序列依赖。Huang 等人[11]首次将 Mamba 引入 RGB-Event 跟踪，提出了 Mamba-FETrack，利用 Mamba 的自回归查询能力捕捉目标外观随时间的变化；随后 Mamba-FETrack V2[24]进一步采用统一的 Vision Mamba 框架，结合可学习的提示生成器，在共享提示池基础上为每个模态生成专属提示，在 Mamba 内部统一完成特征提取、交互与融合，显著提升了计算效率与跟踪精度。针对事件数据的稀疏性和运动趋势特性，部分工作认为需要为其设计专门的网络结构。TENet[19]为事件设计了专用的骨干网络（Pooler）与多尺度池化模块，充分利用事件的空间稀疏性和时间运动趋势，在融合阶段提出“互导融合”策略，根据两模态的信息质量相互指导实现自适应特征融合，在多个数据集上明显优于简单的加法或拼接融合；SiamEFT[18]通过自适应时间加权构建事件帧，并在 ANN+SNN 混合孪生结构中采用跨网络融合模块，融合 RGB 空间特征与事件时间特征，探索了脉冲神经网络在融合跟踪中的应用。

除了算法模型的不断迭代,大规模高质量数据集的建立同样是推动 RGB-Event 融合跟踪领域快速发展的关键因素。在早期研究中,受限于事件相机硬件普及度低、采集与标注困难,研究人员多使用小规模自制数据进行实验,不同方法之间的性能难以公平比较,也限制了深度学习方法的应用。为了解决这一问题,近年来多个研究团队陆续构建并公开了具有代表性的大规模基准数据集,涵盖不同的分辨率、序列长度、挑战属性以及模态对齐方式,为算法评估与横向对比提供了统一的平台。当前主流 RGB-Event 跟踪数据集汇总如表 3.4 所示。

表 3.4 主流 RGB-Event 跟踪数据集

数据集	特点	年份
VisEvent	大规模可见光-事件对, 820 视频对, 含低照、高速、复杂背景	2021
FE108	短期 RGB-E 跟踪数据集, 用于评估 CEUTrack、Mamba-FETTrack 等	2021
COESOT	大规模彩色-事件跟踪基准, 90 类、1354 序列	2022
FE240Hz	高帧率 (240Hz) 框-事件数据, 用于高帧率跟踪	2023
FELT	首个长序列 RGB-E 跟踪数据集, 1044 视频, 含 14 种挑战属性	2024
CRSOT	首个非对齐高清 RGB-Event 数据集, 1030 视频对, 空间/时间不严格对齐	2024
EventUAV	高动态 UAV 场景 RGB-E 基准, 含复杂运动和 RGB 低可见性	2025

总体而言, RGB-Event 路线更适合目标外观复杂、语义信息重要或单纯事件流触发不足的场景, RGB 图像能够提供更稳定的纹理、颜色和上下文信息; 其主要局限在于两模态之间需要处理空间对齐、时间同步、模态质量波动和 RGB 主导问题, 同时双分支或跨模态交互结构也会带来更高的计算成本。

3.2.3 前沿研究方向

从 2026 年以来的最新研究进展看, 事件相机目标跟踪的关注重点已经不再局限于事件数据能否用于目标跟踪这一基础问题, 而是进一步转向如何围绕事件流的异步性、稀疏性、动态密度变化以及跨模态错位特性构建更具针对性的建模框架。与早期工作相比, 当前研究一方面更加重视事件数据本身的物理统计特性, 另一方面也更加关注事件跟踪系统在真实复杂场景中的部署效率与鲁棒性。因此, 若从研究趋势而非单篇方法创新的角度加以概括, 当前事件相机目标跟踪领域的前沿方向主要可以归纳为以下五个方面。

面向事件稀疏性与动态密度变化的自适应建模。纯事件目标跟踪正在从固定事件表示和固定计算路径, 转向围绕事件稀疏性、目标速度和局部动态强度进行自适应建模。由于事件流的信息密度会随运动速度和场景动态显著变化, 统一的时间窗口和统一的推理强度往往难以兼顾低速场景下的信息不足与高速场景下的事件拥挤问题。这一趋势在 2026 年的工作中表现得较为明显。Dynamic Pondering Sparsity-aware Mixture-of-Experts Transformer 通过多密度事件输入、稀疏性感知专家网络和动态推理深度, 使模型能够根据事件分布自适应选择计算路径 [27]。TSETrack 则利用 token

稀疏化减少无效注意力计算 [40], 而 Adaptive Spatial-Temporal Window 进一步表明, 事件窗口本身也应根据速度异质性动态调整 [20]。这说明未来的事件单模态跟踪将更加重视输入驱动的自适应表示与自适应推理。

从黑盒融合转向显式对齐、质量感知与几何先验融合。 RGB-Event 融合仍是当前研究主线, 但其核心问题已不再是简单引入双模态信息, 而是如何在时间分辨率、空间分辨率、噪声分布和信息密度均不一致的条件下实现稳定融合。越来越多的工作开始指出, 若忽略这些模态差异而直接进行特征拼接或黑盒注意力融合, 往往会导致跨模态错位、事件信息利用不足甚至 RGB 主导现象 [8, 28, 43]。围绕这一问题, AlignTrack 强调先对齐、再融合的思路 [21]; MambaTrack 将事件密度显式引入状态转移和门控融合 [37]; MEMLTrack 和 DualFormer 说明事件模态不宜被压缩为单一辅助图像, 而应通过多表示和多层级交互释放结构信息与时间信息 [1, 7]; SOR-Track 则进一步把事件方向结构视为可解释的几何先验, 用于修正退化的 RGB 纹理特征 [9]。整体上看, RGB-Event 融合正在从黑盒特征混合演进为显式对齐、模态质量感知和几何先验驱动的融合框架。

从低照和高速场景扩展到严重遮挡与复杂非线性运动。 事件相机在目标跟踪中的早期优势主要体现在低照度、高动态范围和高速无模糊场景中, 而 2026 年的研究进一步表明, 事件流的高频时间线索还可在严重遮挡和复杂非线性运动下承担轨迹维持功能。这意味着事件相机目标跟踪的鲁棒性优势正在从光照和速度优势扩展到复杂动态连续性优势。Tracking through Severe Occlusion via Event-Derived Transient Cues 是这一方向的代表工作。该方法通过事件派生的瞬态运动线索建模帧间位移, 并利用双向运动一致性约束处理高速非线性运动, 从而在严重遮挡期间维持更稳定的轨迹估计 [3]。这类工作说明, 事件相机的价值不应仅理解为提升极端场景下的成像质量, 更应理解为在空间外观匹配不可靠时, 为目标状态传播提供更细粒度的时间连续性约束。

面向实时系统的轻量化、低功耗与神经形态部署。 随着事件相机逐步进入机器人、无人机和边缘设备, 目标跟踪研究的评价重点也在发生变化。相比仅追求离线 benchmark 上的精度提升, 越来越多的工作开始关注方法能否在资源受限条件下长期、稳定、低功耗地运行。这表明事件相机目标跟踪正在从单纯的算法问题转向系统问题。在这一方向上, TSETrack 和 Dynamic Pondering Transformer 分别利用 token 稀疏化和动态推理深度降低冗余计算 [27, 40]; LASTracker 通过 ANN-SNN 混合结构兼顾融合鲁棒性与低功耗部署 [33]; SpikeTrack 则尝试构建面向事件输入的高性能脉冲神经网络跟踪器 [32]; UETrack 也从统一多模态与多硬件平台部署角度体现了这一趋势 [12]。总体上, 未来高价值的事件跟踪方法不仅需要在复杂场景下保持精度, 还需要在低延迟、低功耗和边缘端部署条件下实现稳定推理。

从二维边界框跟踪扩展到三维连续状态估计与 6DoF 位姿跟踪。 2026 年还有一个明显趋势, 即事件相机目标跟踪的研究边界正在从二维边界框跟踪向三维连续状态估计扩展, 尤其表现为基于事件相机的 6DoF 目标位姿跟踪快速升温。虽然 6DoF 位姿跟踪已超出传统单目标边界框跟踪的定义, 但两者都属于在高速动态、低照、遮挡和大位移条件下对目标状态进行连续估计的问题, 因此可被视为事件目标跟踪的重要

扩展方向。Event6D、EDFT、Keypoint-based Dynamic Object 6-DoF Pose Tracking 以及 Event-based Motion Appearance Fusion 分别展示了事件-深度协同重建、事件距离场配准、关键点连续跟踪以及非学习几何传播等不同路线 [13, 14, 16, 34]。这些工作说明, 事件相机目标跟踪不应被狭义理解为二维框回归问题, 在机器人操作、视觉伺服和高速交互任务中, 事件相机更可能承担连续三维状态估计的角色。

3.3 技术路线小结

总体来看, Event-Only 路线更强调事件相机本身的低延迟和高速响应能力, 适合在硬件资源受限、RGB 图像不可用或极端动态场景中使用; RGB-Event 路线则通过引入 RGB 外观信息提高目标语义和纹理表达能力, 是当前可见光-事件协同跟踪的主流方向。两类方法的共同挑战在于如何充分利用事件流的细粒度时序结构, 并在噪声、遮挡、静止目标和复杂背景下保持稳定跟踪。

第四章 ViPT 与 SDSTrack 算法复现

按照课程设计题目要求，本文选取 ViPT 与 SDSTrack 两种代表性 RGB-E 跟踪方法进行复现与分析。本章不只停留于算法流程的平面描述与结果展示，而是从模型机制概述、复现设置及实验结果三个层面展开论述，以建立后续改进实验所依赖的可信基线。

4.1 ViPT 算法分析与复现

4.1.1 方法概述

ViPT (Visual Prompt Multi-Modal Tracking) 是一种基于视觉提示学习的多模态目标跟踪框架，其核心思想是在尽可能保留大规模 RGB 跟踪预训练知识的前提下，以少量可训练参数将单模态跟踪模型迁移到 RGB-D、RGB-T 和 RGB-E 等多模态场景中 [43]。与传统多模态跟踪中常见的全量微调策略相比，ViPT 更强调参数高效迁移：它并不试图为辅助模态构造一条与 RGB 完全对称的重型分支，而是将辅助模态压缩为能够调节 RGB 主干表示的 prompt，并通过该 prompt 学习多模态互补信息。

从具体结构看，ViPT 以基于 ViT 的 RGB 跟踪器作为 foundation model，模板图像与搜索图像的 RGB patch token 直接送入冻结的主干网络；辅助模态则通过级联的 modality-complementary prompter (MCP) 逐层生成 prompt token，并以残差形式注入 RGB token 序列。MCP 的设计并不是简单拼接两种模态，而是先将 RGB 中间表示与辅助模态表示分别投影到低维空间，再对 RGB 表示执行 spatial fovea 操作以强化更有判别性的空间区域，随后完成跨模态融合并映射回原维度 [43]。因此，辅助模态在 ViPT 中承担的是调节基础表征的角色，而不是独立承担一套完整的特征提取与决策任务。其网络架构如4.1所示。

这种设计带来了两个直接结果。其一，ViPT 可以最大限度继承 RGB 预训练主干在大规模数据上学到的通用表征能力，从而降低多模态小样本场景下的过拟合风险。其二，训练参数显著减少，使得模型在工程上具有更好的迁移性与部署友好性。然而，这一优势也对应着清晰的边界：由于辅助模态只能通过 prompt 间接影响主干表示，其对深层语义与时序结构的改写能力受到限制。特别是在 RGB-E 任务中，ViPT 实际处理的是由原始事件流转换得到的事件图像，而不是直接对异步事件序列进行原生建模 [43]。因此，它更准确地说是一种面向 RGB-E 场景的参数高效跨模态适配框架，而非充分挖掘事件时序优势的事件原生跟踪方法。

4.1.2 实验环境与训练设置

ViPT 的复现工作在 AutoDL 云端平台完成，软硬件环境配置如表 4.1所示。为了保证复现结果具有可比性，训练过程中尽可能保持与官方实现一致的数据集划分、输




图 4.1 ViPT 网络架构示意图

入尺寸、batch size、学习率、优化器与训练 epoch，其具体设置见表 4.2。

表 4.1 ViPT 复现环境配置 (AutoDL)

项目	配置
操作系统	Ubuntu 18.04
GPU	NVIDIA RTX 2080 Ti $\times 2$ (22 GB)
CUDA	11.3
Python	3.8
PyTorch	1.7
主要依赖	Torchvision、NumPy、PyYAML 等

需要指出的是，ViPT 属于训练与测试一体化复现范式，其最终性能不仅受推理脚本影响，也会受到训练随机性、硬件数值行为、数据加载细节和优化稳定性的共同作用。因此，对这类方法的复现判断重点不应是机械追求逐项数值完全一致，而应考察复现模型是否保留了原方法的性能层级、指标走势及主要行为特征。

4.1.3 复现结果与分析


原始结果与复现结果均采用移植自官方 MATLAB 工具包的 Python 评测脚本进行计算，并处理了缺席帧排除、首帧强制对齐及无效框替换规则。相较于只比较最终数字，这一评测协议的一致性本身就是结果可信度的重要组成部分。

表 4.2 训练参数设置


参数	输入尺寸	Batch Size	Learning Rate	Optimizer	Epoch
设置	256	32	0.004	AdamW	60

ViPT 在 VisEvent 测试集上的复现结果如表 4.3, 图 4.2a、图 4.2b、图 4.2c 与图 4.2d 所示。本文复现模型在 Success AUC、Precision@20 和 SR@0.50 三项指标上均略低于论文报告值, 其中 Precision@20 相较论文值下降约 1.7%, SR@0.50 下降约 0.3%。从数值上看, 这一偏差处于可接受范围内; 从结构上看, 不同指标表现为一致的小幅回落, 而非某一指标异常失真。这说明当前复现结果更接近于合理环境差异下的性能波动, 而不是实现错误导致的结构性偏移。


总体来看, 本文复现结果与论文报告值基本一致, 仅存在小幅下降。考虑到训练与推理硬件、运行环境以及随机初始化等因素均与原论文存在差异, 这一偏差可视为合理的复现波动范围。因此, 本文认为 ViPT 已被较为成功地复现, 当前结果差异不足以说明方法本身存在明显的不稳定性问题。




(a) 复现 precise 曲线



(b) 复现 success 曲线



(c) 不同情境下复现结果和原始结果 Precise 柱状对比图



(d) 不同情境下复现结果和原始结果 AUC 柱状对比图

表 4.3 ViPT 在 VisEvent 测试集上的复现结果

指标	论文报告值	本次复现	偏差
Success AUC	-	0.612	-
Precision @ 20px	0.758	0.745	-1.7%
SR @ 0.50	0.592	0.590	-0.3%

4.2 SDSTrack 算法分析与复现

4.2.1 方法概述

SDSTrack (Self-Distillation Symmetric Adapter Learning for Multi-Modal Visual Object Tracking) 同样建立在 RGB 预训练单流跟踪器之上, 但它与 ViPT 的关键差异不在于是否追求参数高效, 而在于它把多模态关系如何建模本身当成核心问题。已有多模态跟踪方法虽然引入了双模态输入, 但在实际结构中常常保留明显的 RGB 主导倾向, 即 RGB 模态承担主要表征任务, 辅助模态更多扮演补充角色。SDSTrack 则试图通过更对称的结构设计削弱这种偏置 [8]。

其主体由 symmetric multimodal adaptation (SMA) 和 complementary masked patch distillation 两部分构成。SMA 又可细分为 cross modal adaptation (CMA) 与 multimodal fusion adaptation (MFA)。其中, CMA 通过在 X 模态特征提取路径中插入轻量 bottleneck adapter, 把 RGB 预训练主干的特征提取能力迁移到 X 模态; MFA 则复用若干 ViT block 作为融合阶段, 将 RGB 与 X 模态 token 拼接后送入带 adapter 的融合块, 并利用注意力掩码抑制同模态自注意, 强化跨模态交互 [8]。由此可见, SDSTrack 不是将辅助模态压缩为提示后附着在 RGB 主干上, 而是试图在中高层表示中让两个模态以更对称的方式共同参与特征建模。图 4.3 展示了 SDSTrack 的整体框架。

在此基础上, SDSTrack 又进一步提出 complementary masked patch distillation。该模块对两种模态施加互补随机 patch mask, 保证任一空间位置至少有一条模态路径保持有效; 随后构造 clean path 与 masked path, 两条路径共享网络参数, 并在每个融合阶段利用均方误差执行自蒸馏, 让 clean path 的融合特征监督 masked path 的融合特征 [8]。这一设计的意义不只是数据增强, 更在于迫使模型学习当某一模态退化甚至缺失时, 如何从另一模态补足信息。因此, 相比 ViPT 主要解决如何低成本引入辅助模态, SDSTrack 更直接地回应了如何缓解模态主导与模态退化这一问题。

不过, SDSTrack 的边界同样清晰。虽然其结构更强调多模态对称性与鲁棒性, 但它依然是建立在帧式对齐表示上的多模态图像跟踪器, 并没有直接对原始异步事件流进行原生时序建模。换言之, SDSTrack 缓解了模态不对称问题, 却没有从根本上解决事件时间结构在帧式表示中被压缩的问题。




图 4.3 SDSTrack 网络框架示意图（引自原论文）

4.2.2 复现策略与实验环境

与 ViPT 不同，SDSTrack 采用推理评估复现策略。考虑到上游代码基于 PyTorch 1.11.0 与 Python 3.8，且官方已提供 RGB-E 预训练权重，本文直接在官方预训练模型基础上对 VisEvent 测试集进行完整评估，以验证论文报告指标在当前环境中的可复现性。由此决定了 SDSTrack 复现工作的关键不在于重新训练过程是否稳定，而在于预训练权重是否一致、评测协议是否严格对齐。复现工作在 RunPod 云端平台完成，实验环境如表 4.4 所示。

复现过程中，VisEvent 测试集共包含 320 个序列，原始数据体积约 102 GB，因此本文将完整测试集组织为 WebDataset 格式，以支持流式读取和分片推理。同时，对 SDSTrack_cvpr2024_rgbe.pth.tar 进行了多源一致性校验，确认其 SHA256 一致且推理指标与论文预期相符。前者保证了大规模数据在云端环境中的可操作性，后者则直接保证了评估对象与官方模型的一致性。

表 4.4 SDSTrack 复现环境配置（RunPod）

项目	配置
操作系统	Ubuntu 22.04
GPU	NVIDIA RTX 3090 (24 GB)
CUDA	12.4
Python	3.11
PyTorch	2.4.0
主要依赖	Torchvision、NumPy、PyYAML、timm 等

4.2.3 复现结果与分析

SDSTrack 在 VisEvent 测试集上的复现结果如表 4.5所示。本文复现得到 Success AUC = 0.5829、Precision@20 = 0.7506、SR@0.50 = 0.6929。与论文报告值相比，Success AUC 偏差约为 -1.4%，Precision@20 偏差约为 -1.6%。从绝对数值上看，这一偏差与 ViPT 处于相近量级，因此可以认定复现整体是成功的。

值得注意的是，在修正评测脚本之前，未排除缺席帧的朴素 Python 实现曾得到 SDSTrack Success AUC = 0.6252、Precision = 0.7715 的虚高指标，较论文高出约 2.8%。这一偏差充分说明 VisEvent 数据集的缺席帧处理对最终评价具有显著影响，也凸显了严格遵循官方评测协议的重要性。

表 4.5 SDSTrack 在 VisEvent 测试集上的复现结果

指标	论文报告值	本次复现	偏差
Success AUC	0.597	0.5829	-1.4%
Precision @ 20px	0.767	0.7506	-1.6%
SR @ 0.50	—	0.6929	—

第五章 基于 ViPT 的改进方法设计与实验

在建立复现基线之后，本文进一步围绕 ViPT 的结构性局限展开轻量改进。由于课程设计的时间与算力条件有限，改进目标并非重写整套网络，而是在尽量不改变主干结构的前提下，针对复现中暴露出的关键问题做局部增强，并分析这一增强究竟改善了什么、又没有解决什么。

5.1 ViPT 原始方法存在的问题

结合原始框架与复现实验观察，ViPT 在 RGB-E 跟踪场景中的主要局限可以概括为四点：

1. **固定且单一的初始模板：**模型仅以目标首次出现帧中的区域经简单裁剪与缩放作为模板，并在整个跟踪过程中保持不变，未考虑目标在时序过程中可能出现的显著外观变化，如视角变化、非刚性形变等。
2. **时序信息缺失：**模型始终仅在当前帧上独立操作，未建立历史帧信息的传递与利用机制，因而缺乏时序推理能力。目标跟踪任务本身具有强烈的时序属性，在复杂真实场景中，人类往往需要结合先前帧的记忆来推断目标在当前帧的位置，并借助当前帧的观测进行交叉验证。
3. **过强的位置先验假设：**模型内置了较强的目标运动先验，即假设相邻帧之间目标位移较小。据此，模型以上一帧检测到的目标位置为中心对图像进行裁剪，并对最终检测结果施加中心距离加权（汉宁窗）以计算得分，因而当有极其相似的目标出现在目标的附近时，将产生严重的错判，同时该先验也默认排除了目标极高速运动的情形。
4. **模板匹配机制的固有缺陷：**无论在 RGB 模态还是事件数据模态上，模型仅执行单纯的模板匹配，未能有效利用事件数据的特点。事件相机的核心优势在于其可作为运动传感器使用，而非仅仅是一台“高速相机”，其数据具有突出的时序特征。这导致模型在事件相机所擅长的高速运动等场景下未能发挥出应有性能。

受限于时间与资源，本文优先围绕第一点，即固定模板难以适应目标外观动态变化这一缺陷，设计轻量在线模板更新策略，并将其作为对 ViPT 的局部改进。

5.2 改进思路

基本思路是在保留 ViPT 原始初始模板的同时，为 RGB 与事件模态各引入一组可在线更新的动态模板，以补充目标在后续时序中的外观变化信息。该策略并不试图用

在线模板替代初始模板，而是将初始模板作为稳定参考，将在线模板作为随时间变化的补充信息源，从而在稳定性与适应性之间取得平衡 [38]。

这一设计基于一个直接的观察：对于模板匹配型跟踪器而言，性能下降往往并不只是因为检测头不够强，而是因为模板与目标当前外观之间出现了持续分布偏移。在线模板的价值就在于缩小这种偏移，但其风险也同样明显，即错误更新可能进一步加速漂移。因此，本节真正需要解决的问题并不是是否更新模板，而是在什么条件下更新才尽可能可靠。

5.3 动态模块原理

为降低错误模板污染的风险，采用更新间隔 + 置信度阈值 + 相似度校验的联合更新准则。首先，仅当距离上一次更新达到最小更新间隔时，模型才考虑再次更新模板，以避免过于频繁的替换破坏系统稳定性。其次，当前预测结果的置信度必须高于预设阈值，从而减少低质量检测驱动错误更新的风险。最后，在通过置信度筛选后，还需对当前候选模板与最可信模板之间的外观相似性进行检验，只有相似度足够高时才真正执行更新。

相似度判别仅使用 RGB 模态信息，而不直接依赖事件模板。原因在于，RGB 外观在跨帧层面具有更强的稳定性，更适合承担模板可信性判断的角色；相比之下，事件表示对短时运动更敏感，其时不变性较弱，若直接以事件模板作为相似度门控，反而更容易引入不稳定更新。因而，本文采用以 RGB 模态进行更新判别，同时对 RGB 与事件模板执行联合更新的折中方案。大致代码流程见附录。

同时我们认为，该简洁的动态在线模板机制在一定程度上实现了对时序信息的弱利用，即通过动态模板这一媒介进行了时序信息的传递。我们也尝试了只使用一组动态更新的模板，但是效果非常的糟糕，我们认为是这样的一种方式不够鲁棒，容易引入错误消息，如果没有初始模板的正确信息补充，会严重损害模型性能。

5.4 改进信息流设计

针对所引入的在线模板的使用方式，我们在不改变模型整体架构且无需重新训练的前提下，经过多种尝试，最终采用了如下方案：在线模板与初始模板均从原始帧中截取而得，二者数据分布一致。因此，我们沿袭模型原有的模板处理方式，对在线模板进行相同的操作，随后将在线模板对应的 token 直接拼接到初始模板 token 之后，再输入原始注意力层进行计算。完成计算后，我们对输出结果进行拆分，将在线模板 token 与初始模板 token 分离，并分别执行相同的后续处理。处理完毕后，再次进行相同的拼接操作，继而送入注意力层。经过 backbone 处理得到的特征同样进行分离，剥离出属于在线模板的字段，再送入检测头以得到最终预测结果，大致流程可见图 5.1。这一设计无需改动检测头的架构，亦不影响后续操作与计算。

这种设计的优点在于低侵入性。一方面，它能够在不改动原始检测头结构的前提下，把动态模板纳入原始信息流；另一方面，它也保留了初始模板作为长期稳定参照

能够在部分场景中改善跟踪性能。这种提升是在保持原有框架不变的前提下取得的，因而更适合被理解为对固定模板局限性的补充，而不是对原有跟踪框架的整体重构。




图 5.2 改进前后 precise 对比




图 5.3 改进前后 AUC 对比

5.5.2 定性结果分析

定性结果表明，改进方法的收益主要体现在目标运动较明显、位置变化较大或存在相似目标干扰的情形下。这一差异更适合结合视频过程进行观察，静态截图只能呈现其中的局部结果。本文选取 video_0079 作为代表性样例，见图 5.4（相对应的对比视频：<https://github.com/kriss-spy/EvTrack>），其中绿框表示真实标注，蓝框表示预测结果。当一个相似目标从被跟踪目标背后经过时，原始方法后续发生误跟踪并锁定到干扰目标，而改进方法仍能保持正常跟踪，说明在线模板在该类动态场景中能够提供更贴近当前外观的参考信息。

与此同时，原始实验结果也表明，该改进并非在所有场景下都带来增益。在 deformation、over exposure 等场景中，性能反而可能下降。其原因在于，简单的在线模

表 5.1 不同方法跟踪性能对比

方法	Precision	Success/AUC	说明
官方 ViPT	75.4	62.0	官方发布结果
我们的 ViPT	74.5	61.2	AutoDL 复现结果
改进 ViPT	75.4	61.9	本文改进方法
SDSTrack (官方)	76.7	59.7	论文报告结果
SDSTrack (复现)	75.1	58.3	云端推理评估结果

板更新在这些场景下更容易引入错误模板，并将错误外观信息继续传递到后续匹配过程中；相对地，在目标外观持续变化的场景中，连续更新策略更容易发挥作用。




图 5.4 其中绿框为 gt，蓝框为预测，在 video_0079 数据中，当有一个相似的目标从目标背后经过时，原始的方法后续追踪错误，锁定到了干扰目标身上，但是我们的方法依旧正常追踪

5.5.3 实时性分析

对我们的改进模块进行分析，可知延时可能来源为：1、模板更新，2、新引入的模板带来的计算延时。

在我们的硬件环境上，原始模型 GPU 推理平均延时在 0.025 s 左右，而我们改进版 GPU 推理平均延时在 0.035 s 左右，我们认为是引入的动态模板让 token 数变长，导致进行 Transformer 的注意力计算时让延时和计算量进一步上升，而带来的 GPU 内存占用量平均在 20MB 左右。同时我们的改进方案中，引入了更多的矩阵的分离和合

并操作，也一定程度上引入了较多的操作量和延时。

其中模板更新的主要延时压力在于图片的相似性计算过程，并在 CPU 上进行。在我们实验的硬件上，发现没有满足相似性计算的条件时，平均延时在 $1e-06$ s 左右浮动，基本上可以忽略不计；当需要计算相似性时，这一环节带来的平均延时为 0.002 s 左右，但是这样的相似性计算并没有时常发生。当我们设定更新间隔为 10 时，经过一定的统计发现，需要相似性计算的次数占比 $< 1/10$ ，因而这一环节平均的延时约在 0.0002 s 左右，相较于模型的推理延时来说可以忽略不计。

5.6 后续改进方案猜想

时序信息的更好利用：在许多相关研究中 [42][36]，最朴素的做法是将当前帧与历史多帧一并输入网络，利用注意力机制促使当前帧信息与先前帧信息进行交互，从而赋予模型一定的时序推理能力。该方案在 ViPT 的原有架构上较易实现，但会导致计算量呈几何级数增长，故未具体实践。另一种方案是使用一个 token 在帧间传递信息 [42]，该 token 从上一帧传递至下一帧，类似于 RNN 中的隐状态传递。我们对此进行了初步尝试，采用一个时序步长的 token 进行信息传递，但效果均不明显，甚至导致模型性能下降。

我们推测，由于未改动 ViPT 的原始架构，缺乏专门设计的环节来处理此类信息传递，对于这种用于传递时序信息的 token 位需要一个独特的标识 embedding，一定程度上需要网络学习、适应，如在 [42] 中设计有一个 embedding 对这一 token 位进行独特的标识，由于我们没有变动 ViPT 网络结构，并没有这样的标识位，导致 ViPT 网络并没有意识到这一部分的独特性，信息未能有效传递，反而损害了模型能力。

位置先验与模板匹配机制的固有缺陷：这两点密切相关，因此合并讨论。首先，我们认为这种位置先验在存在相似目标干扰的复杂场景中会严重失效，甚至显著损害模型性能。其设计初衷具有一定合理性，即期望利用物体的运动状态信息辅助预测。然而，可以通过更好地利用事件数据的特点来达成这一目的。

近年来，事件相机目标跟踪领域越来越多的方法 [39][15][30] 采用如下方案：将事件数据表示为保留时序的结构（如体素网格），而非压缩为单帧，再输入网络计算；或利用时空 Transformer、RNN 对历史信息进行编码，使模型能够自适应地学习目标目标的运动特性。现代事件相机目标跟踪模型的核心竞争力，正在于其对时序运动信息的利用能力，而纯粹的“模板匹配”方法在面对快速运动、复杂背景、尺度剧变及遮挡时已捉襟见肘。因此，我们认为，在保留 ViPT 原始架构的基础上，可以添加更为独特且轻量化的模块来处理和利用事件数据，在仅增加少量训练参数的前提下，进一步提升事件数据的利用效率，以增强模型在极端情况下的鲁棒性，或者直接将专门用于纯事件相机追踪的模型和纯 RGB 目标追踪的模型结合起来，引入中间少量的交融层和可训练参数，一方面适配数据量少的问题，另一方面来提升整体的能力。

同时，随着模型推理能力的不断上升，模型的体积和所需的训练参数也在不断增

加，对数据更加渴求。ViPT 原始设计的出发点就是应对多模态训练数据不足的问题，在 RGB 知识的基础上对其他模态的数据进行理解与处理，因而没有较好地利用其他模态的数据特点，如事件数据的高时效性，在一些困难、复杂的情境下出现明显的性能下降是预料之中的。

第六章 总结与展望

6.1 工作总结

本文围绕基于事件相机的目标跟踪任务，完成了事件相机原理分析、相关文献调研、数据集与评价指标整理、ViPT 与 SDSTrack 复现方案设计、改进方法构建以及实验分析框架搭建。其中 ViPT 在 AutoDL 完成训练与推理复现，SDSTrack 则在 RunPod 云端完成基于官方权重的全量推理评估，最终指标与论文报告值偏差均在 2% 以内。调研表明，事件相机目标跟踪的发展主线已经从早期事件图像重建与纯事件跟踪，逐步演化到以 RGB-E 融合、多模态适配和高分辨率评测为核心的新阶段。通过引入事件时序建模、动态融合和噪声抑制思想，有望进一步提升极端光照和高速运动场景下的跟踪鲁棒性。

6.2 不足之处

我们所设计的改进模块虽然取得一定的成效，但是面对一些极端情况依旧会失效，如在一些有着相似的目标对追踪目标进行严重的遮挡和覆盖时，会严重损害模型的性能，会让模型后续的追踪到这些干扰物体上，而不是预期的目标，我们认为这种情况下更容易产生错误的模板，给模型引入了错误的信息，损害模型的能力。同时我们认为这样的一种简单的修补方案的前提是模型具备着较好的检测能力，如果模型自身并不具备这一能力，会导致产生大量的错误模板，进而损害模型的性能。并且我们这样一种简单的改进，对新引入的信息的利用率并不高，大致上让模型的 fps 下降了 40% 左右，需要一种更为高效的方式来进行时序信息的传递和使用。

6.3 未来展望

我们现有的多模融合检测方案对事件数据信息的利用程度没有十分的高效，在一些复杂情境下，如剧烈的远近大小变化、背景干扰等等，会让性能下降严重，很多本质上还是在做单纯的图像匹配，并没有利用多帧的事件信息进行时序位置上的推理，一定程度上和人类在复杂情景下的目标跟踪存在着底层机制上的差异，但是受限于时间、资源的限制，我们难以对这一方向做更加深入的探索，但是我们相信这一方向依旧存在着充足的发展和探索空间。

此外，本课程设计中将复现所用的预训练权重、数据集及评测脚本统一托管至 Hugging Face 社区平台，有助于推动事件相机目标跟踪领域的标准化与可复现性，降低后续研究者的环境搭建与数据获取门槛。

参考文献

- [1] Dualformer: A dual-branch transformer framework for frame-event tracking with complementary fusion attention and sparse spatial channel attention. *Engineering Applications of Artificial Intelligence*, 2026.
- [2] Omar Abdelaziz, Mohamed Shehata, and Mohamed Mohamed. Beyond traditional single object tracking: A survey. *arXiv preprint arXiv:2405.10439*, 2024.
- [3] Hao Dong, Yujin Liu, Haoyue Liu, Zhenyu Wang, Shihan Peng, Zhiwei Shi, Yi Chang, and Luxin Yan. Tracking through severe occlusion via event-derived transient cues. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.
- [4] Guillermo Gallego, Tobi Delbrück, Garrick Orchard, Chiara Bartolozzi, Brian Taba, Andrea Censi, Stefan Leutenegger, Andrew J. Davison, Jörg Conradt, Kostas Daniilidis, and Davide Scaramuzza. Event-based vision: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(1):154–180, 2022.
- [5] D. Gehrig, H. Rebecq, G. Gallego, and D. Scaramuzza. Eklr: asynchronous photometric feature tracking using events and frames. *IJCV*, 2020.
- [6] Qing Guo, Wei Feng, Zhihao Chen, Ruijun Gao, Liang Wan, and Song Wang. Effects of blur and deblurring to visual object tracking. *arXiv preprint arXiv:1908.07904*, 2019.
- [7] Yuting He, Bin Fan, Zhexiong Wan, Qi Liu, and Yuchao Dai. Multi-event representation and multi-level fusion for robust rgb-event object tracking. *Knowledge-Based Systems*, 2026.
- [8] Xiaojun Hou, Jiazheng Xing, Yijie Qian, Yaowei Guo, Shuo Xin, Junhao Chen, Kai Tang, Mengmeng Wang, Zhengkai Jiang, Liang Liu, and Yong Liu. Sdstrack: Self-distillation symmetric adapter learning for multi-modal visual object tracking. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.
- [9] Dexing Huang, Shiao Wang, Fan Zhang, and Xiao Wang. Spatial orthogonal refinement for robust rgb-event visual object tracking. *arXiv preprint arXiv:2603.27913*, 2026.
- [10] J. Huang, S. Wang, M. Guo, and S. Chen. Event-guided structured output tracking of fast-moving objects using a celex sensor. *IEEE Transactions on Circuits and Systems for Video Technology*, 2018.

- [11] J. Huang, S. Wang, S. Wang, Z. Wu, X. Wang, and B. Jiang. Mamba-fetrack: Frame-event tracking via state space model. *arXiv preprint arXiv:2404.18174*, 2024.
- [12] Ben Kang, Jie Zhao, Xin Chen, Wanting Geng, et al. Uetrack: A unified and efficient framework for single object tracking. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.
- [13] Jae-Young Kang, Hoonhee Cho, Taeyeop Lee, Minjun Kang, Bowen Wen, Youngho Kim, and Kuk-Jin Yoon. Event6d: Event-based novel object 6d pose tracking. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.
- [14] Yufan Kang, Ryoichi Ishikawa, Guillaume Caron, and Takeshi Oishi. Event-based 6-dof object tracking with distance field reaching 130 hz. *IEEE Robotics and Automation Letters*, 2026.
- [15] Jianing Li, Jia Li, Lin Zhu, Xijie Xiang, Tiejun Huang, and Yonghong Tian. Asynchronous spatio-temporal memory network for continuous event-based object detection. *IEEE Transactions on Image Processing*, 31:2975–2987, 2022.
- [16] Zhichao Li, Chiara Bartolozzi, Lorenzo Natale, and Arren Glover. Event-based motion & appearance fusion for 6d object pose tracking. *arXiv preprint arXiv:2603.08264*, 2026.
- [17] H. Liu, D. P. Moeyes, G. Das, D. Neil, S.-C. Liu, and T. Delbruck. Combined frame- and event-based detection and tracking. In *ISCAS*, 2016.
- [18] S. Liu, G. Wang, Y. Song, J. Huang, Y. Huang, Y. Zhou, and S. Wang. Siameft: adaptive-time feature extraction hybrid network for RGBE multi-domain object tracking. *Frontiers in Neuroscience*, 18:1453419, 2024.
- [19] P. Shao, T. Xu, Z. Tang, L. Li, X. Wu, and J. Kittler. Tenet: Targetness entanglement incorporating with multi-scale pooling and mutually-guided fusion for RGB-e object tracking. *Neural Networks*, 178:106412, 2024.
- [20] Zhipeng Sui, Haiqing Hao, Weihua He, Seng-Hong Lee, and Wenhui Wang. Adaptive spatial-temporal window: Unlocking the potential of event cameras in heterogeneous velocity scenarios. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.
- [21] Chuanyu Sun, Jiqing Zhang, Yang Wang, Yuanchen Wang, Yutong Jiang, Baocai Yin, and Xin Yang. Aligntrack: Top-down spatiotemporal resolution alignment for rgb-event visual tracking. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2026.

- [22] C. Tang, X. Wang, J. Huang, B. Jiang, L. Zhu, J. Zhang, Y. Wang, and Y. Tian. Revisiting color-event based tracking: A unified network, dataset, and metric. *Pattern Recognition*, 126:108578, 2022.
- [23] M. Wang, F. Shi, X. Cheng, and S. Chen. Prior knowledge-driven hybrid prompter learning for RGB-event tracking. *IEEE Transactions on Circuits and Systems for Video Technology*, 35:8679–8691, 2025.
- [24] S. Wang, J. Huang, Q. Ma, J. Gao, C. Xu, X. Wang, L. Chen, and B. Jiang. Mamba-fetrack v2: Revisiting state space model for frame-event based visual object tracking. *arXiv preprint arXiv:2506.23783*, 2025.
- [25] S. Wang, X. Wang, H. Zhao, J. Xu, B. Jiang, L. Zhu, X. Zhao, Y. Tian, and J. Tang. Decoupling amplitude and phase attention in frequency domain for RGB-event based visual object tracking. *arXiv preprint arXiv:2601.01022*, 2026.
- [26] Shiao Wang, Xiao Wang, Chao Wang, Liye Jin, Lin Zhu, Bo Jiang, Yonghong Tian, and Jin Tang. Event stream-based visual object tracking: Hdetrack v2 and a high-definition benchmark. *arXiv preprint arXiv:2502.05574*, 2025.
- [27] Shiao Wang, Xiao Wang, Duoqing Yang, Wenhao Zhang, Bo Jiang, Lin Zhu, Yonghong Tian, and Bin Luo. Dynamic pondering sparsity-aware mixture-of-experts transformer for event stream based visual object tracking. *arXiv preprint arXiv:2605.06112*, 2026.
- [28] Xiao Wang, Jianing Li, Lin Zhu, Zhipeng Zhang, Zhe Chen, Xin Li, Yaowei Wang, Yonghong Tian, and Feng Wu. Visevent: Reliable object tracking via collaboration of frame and event flows. *arXiv preprint arXiv:2108.05015*, 2021.
- [29] Xiao Wang, Xufeng Lou, Shiao Wang, Ju Huang, Lan Chen, and Bowei Jiang. Long-term visual object tracking with event cameras: An associative memory augmented tracker and a benchmark dataset. *arXiv preprint arXiv:2403.05839*, 2024.
- [30] Xiao Wang, Chao Wang, Shiao Wang, Xixi Wang, Zhicheng Zhao, Lin Zhu, and Bowei Jiang. Mambaevt: Event stream-based visual object tracking using state space model. *IEEE Transactions on Circuits and Systems for Video Technology*, 36:278–291, 2024.
- [31] Xiao Wang, Shiao Wang, Chuanming Tang, Lin Zhu, Bo Jiang, Yonghong Tian, and Jin Tang. Event stream-based visual object tracking: A high-resolution benchmark dataset and a novel baseline. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 19248–19257, 2024.
- [32] Yang Wang, Jiqing Zhang, Chuanyu Sun, Qianhui Liu, Huilin Ge, Ziqi Wei, and Xin Yang. Spiketrack: High-performance and energy-efficient event-based object tracking

- with spiking neural network. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026.
- [33] Z. Wang, S. Liu, H. Zheng, et al. Lastracker: A lightweight rgb-e tracking framework with ann-snn adaptive switching. *Pattern Recognition*, 2026.
- [34] Zhe Wang, Qijin Song, Zihao Li, Jingyu Xiao, and Weibang Bai. Keypoint-based dynamic object 6-dof pose tracking via event camera. In *Proceedings of the IEEE International Conference on Robotics and Automation*, 2026.
- [35] W. Xia, J. Zhu, Z. Huang, J. Qi, Y. He, and X. Jia. Towards survivability in complex motion scenarios: RGB-event object tracking via historical trajectory prompting. *Proceedings of the 2025 IEEE International Conference on Robotics and Automation (ICRA)*, 2025.
- [36] Boyue Xu, Yaqun Fang, Ruichao Hou, and Tongwei Ren. Stiformer: Rgb-t tracking via spatial-temporal interaction transformer. *Image and Vision Computing*, 168:105929, 2026.
- [37] Jinlin You, Muyu Li, and Xudong Zhao. Event-adaptive state transition and gated fusion for rgb-event object tracking. *arXiv preprint arXiv:2604.13426*, 2026.
- [38] Di Yuan, Haiping Zhang, Qiao Liu, Xiaojun Chang, and Zhenyu He. Transformer-based rgbt tracking with spatio-temporal information fusion. *IEEE Sensors Journal*, 25(13):25386–25396, 2025.
- [39] Jiqing Zhang, Yuanchen Wang, Wenxi Liu, Meng Li, Jinpeng Bai, Baocai Yin, and Xin Yang. Frame-event alignment and fusion network for high frame rate tracking. *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9781–9790, 2023.
- [40] Jiqing Zhang, Xin Yang, Haoming Tang, Yuanchen Wang, Baocai Yin, Huibing Wang, Xianping Fu, et al. Efficient vision transformer with token sparsification for event-based object tracking. *International Journal of Computer Vision*, 2026.
- [41] Tianlu Zhang, Kurt Debattista, Qiang Zhang, Guiguang Ding, and Jungong Han. Revisiting motion information for RGB-event tracking with MOT philosophy. *Advances in Neural Information Processing Systems*, 37:456–470, 2024.
- [42] Yaozong Zheng, Bineng Zhong, Qihua Liang, Zhiyi Mo, Shengping Zhang, and Xianxian Li. ODTrack: Online Dense Temporal Token Learning for Visual Tracking. *arXiv e-prints*, page arXiv:2401.01686, January 2024.

- [43] Jiawen Zhu, Simiao Lai, Xin Chen, Dong Wang, and Huchuan Lu. Visual prompt multi-modal tracking. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023.

附录 A 改进算法流程

Algorithm 1 在线模板更新算法

参数说明 (Parameters):

τ : 手动设定的分数阈值 (常数, 设为 0.7)

T_{up} : 手动设定的更新周期 (常数, 设为 10)

初始化 (Initialization):

$z_o \leftarrow z_i$

▷ 动态更新的在线模板 (包含 RGB 和 Event)

$m_o \leftarrow m_i$

▷ 在线模板的 mask, 用于 vit_ce 模型

$z_t \leftarrow z_i$

▷ 最确信模板, 用于保存初始信息

$c_{\text{frame}} \leftarrow 0$

▷ 记录距离上一次更新的帧数

```
1: for all  $f \in \text{frames}$  do
2:    $res \leftarrow \text{model}(f, z_o, m_o, z_i, m_i)$ 
3:    $c_{\text{frame}} \leftarrow c_{\text{frame}} + 1$ 
4:   if  $c_{\text{frame}} > T_{\text{up}}$  and  $res.\text{score} > \tau$  then
5:      $tensor \leftarrow \text{sample\_target}(f, res.\text{state})$ 
6:     if  $\text{ssim}(tensor[:, :, 3], z_t[:, :, 3]) > \tau$  then
7:        $z_t \leftarrow tensor$ 
8:        $z_o \leftarrow tensor$ 
9:        $m_o \leftarrow \text{generate\_mask}(tensor, res.\text{state})$ 
10:       $c_{\text{frame}} \leftarrow 0$ 
11:    end if
12:  end if
13: end for
```

上述的 ssim 可以为任意的图片相似性计算算法, 在我们代码中使用的为 skimage 的 structural_similarity.